

UNIVERSIDADE FEDERAL DO ESPÍRITO SANTO - UFES
CENTRO UNIVERSITÁRIO DO NORTE DO ESPÍRITO SANTO - CEUNES
DEPARTAMENTO DE COMPUTAÇÃO E ELETRÔNICA - DCE
BACHARELADO EM ENGENHARIA DA COMPUTAÇÃO

EMANUEL SILVA SERGIO

Análise dos Microdados do ENEM: Uma Abordagem via TF-IDF e Processamento
de Linguagem Natural

SÃO MATEUS, ES

2026

EMANUEL SILVA SERGIO

Análise dos Microdados do ENEM: Uma Abordagem via TF-IDF e Processamento
de Linguagem Natural

Monografia apresentada ao Curso de
Bacharelado em Engenharia da
Computação, do Centro Universitário do
Norte do Espírito Santo, da Universidade
Federal do Espírito Santo, como requisito
parcial para cumprimento do Projeto de
Graduação II

Orientadora: Prof.^a Silvia das Dores Rissino
(UFES).

SÃO MATEUS,ES
2026

RESUMO

A educação brasileira apresenta desafios históricos, evidenciados pelo desempenho insatisfatório em matemática em avaliações de larga escala, como o *Programme for International Student Assessment* (PISA) e o Exame Nacional do Ensino Médio (ENEM). Este trabalho tem como objetivo desenvolver um procedimento lógico que identifique as competências de identificador de competências matemáticas, fundamentado em técnicas de Análise de Dados e Processamento de Linguagem Natural, para a classificação automática das questões do ENEM. O estudo concentra-se na análise do desempenho de estudantes com deficiência visual que realizam a prova laranja, visando identificar lacunas específicas de aprendizagem. A metodologia compreendeu a extração, o tratamento e a análise dos microdados do INEP referentes ao ENEM 2023. Foram avaliadas diferentes abordagens computacionais, incluindo Regras Simples, *Term Frequency*, TF-IDF e Word2Vec. Após testes comparativos, além de procedimentos de normalização textual e otimização de vocabulário, o modelo baseado em TF-IDF apresentou o melhor desempenho, demonstrando maior equilíbrio e precisão na categorização das questões por competências. A validação com dados do ENEM 2024 e a comparação com os gabaritos oficiais permitiram mapear as áreas de maior dificuldade dos estudantes analisados.

Palavras-chave: ENEM. Análise de Dados. Classificação de Texto. TF-IDF. Educação Matemática.

LISTA DE QUADROS, TABELAS, FORMULÁRIO E GRÁFICOS

QUADROS

Quadro 1: vocabulário inicial	25
Quadro 2: Vocabulário Aprimorado	28
Quadro 3: Quantidade de alunos que fizeram a prova	38

TABELAS

Tabela 1: comparativos entre algoritmos de classificação lexical	26
Tabela 2 : comparação entre o algoritmo TF-IDF e o TF-IDF MELHORADO.....	33
Tabela 3 : dispersão das classificações por disciplina e comparação com o gabarito	34
Tabela 4 : validação do algoritmo com os dados do ano de 2024	36
Tabela 5 : Dados da precisão da classificação do algoritmo	42
Tabela 6 : Classificação real das questões usando o gabarito.....	43
Tabela 7 : Comparativo entre modelo e gabarito	44

FIGURAS

Equação fórmula do IDF suavizado.....	31
---------------------------------------	----

GRÁFICOS

Gráfico 1 : O gráfico apresenta a média das notas por cor de prova.....	40
Gráfico 2 : porcentagem de acertos por questão.....	48

SUMÁRIO

1. INTRODUÇÃO.....	6
1.1 PROBLEMA DE PESQUISA.....	7
1.2 JUSTIFICATIVA.....	8
1.3 OBJETIVOS.....	8
1.3.1 Objetivo Geral.....	8
1.3.2 Objetivos Específicos.....	8
2 REFERENCIAL TEÓRICO.....	10
2.1 MICRODADOS ENEM.....	10
2.1.1 ESTRUTURA ORGANIZACIONAL DAS PROVAS DO ENEM.....	10
2.2 DESCRITORES.....	11
2.3 DADOS.....	12
2.3.1 DADOS ABERTOS.....	12
2.3.2 MICRODADOS ENEM.....	12
2.4 ANÁLISE DE DADOS.....	12
2.4.1 TÉCNICAS DE ANÁLISE.....	13
MODELOS DE ANÁLISE CLASSIFICATÓRIA.....	13
2.5 ALGORITMOS DE CLASSIFICAÇÃO TEXTUAL.....	14
a) CLASSIFICAÇÃO SIMPLES.....	14
b) CLASSIFICAÇÃO POR PALAVRAS-CHAVE COM PESOS.....	14
c) TF-IDF.....	15
d) ALGORITMO DE RANKING DE PROXIMIDADE LEXICAL - BM25.....	15
2.6 FERRAMENTAS DE ANÁLISE.....	15
2.6.1 LINGUAGENS DE PROGRAMAÇÃO.....	15
a) Python.....	15
b) Linguagem de Programação R.....	16
2.6.2 AMBIENTES DE ANÁLISES.....	16
a) Google Colab.....	16
B) Replit.....	17
2.7 TRABALHOS RELACIONADOS.....	17
3 TECNOLOGIAS E METODOLOGIA.....	20
3.1 TECNOLOGIAS.....	20
3.2 METODOLOGIAS.....	21
3.2.1 AQUISIÇÃO DOS DADOS.....	21
3.2.2 LIMPEZA DOS DADOS.....	22
3.2.3 DESENVOLVIMENTO.....	22
3.2.4 ESCOLHA DOS ALGORITMOS.....	23
3.2.5 VOCABULÁRIO.....	25
3.2.6 ESCOLHA DO ALGORITMO FINAL.....	27
3.2.7 OTIMIZAÇÃO DO ALGORITMO.....	29
A) OTIMIZAÇÃO DO VOCABULÁRIO.....	29

B) STOPWORDS.....	31
C) IDF SUAVIZADO.....	31
D) EXPANSÃO AUTOMÁTICA DE VOCABULÁRIO.....	32
E) NORMALIZAÇÃO.....	33
3.2.8 CLASSIFICADOR FINAL.....	33
3.2.9 VALIDAÇÃO.....	36
4. RESULTADOS E DISCUSSÕES.....	39
4.1 ANÁLISE EXPLORATÓRIA.....	39
4.1.1 COMPARATIVO ENTRE AS PROVAS.....	39
4.1.2 MÉDIA GERAL POR COR DE PROVA.....	40
4.2 ANÁLISE DAS QUESTÕES.....	41
a) ANÁLISE DOS DADOS USANDO O TF-IDF.....	43
b) ANÁLISE DOS DADOS USANDO O GABARITO.....	44
4.3 COMPARAÇÃO DOS RESULTADOS.....	45
5 CONCLUSÃO E TRABALHOS FUTUROS.....	47
6 REFERÊNCIAS BIBLIOGRÁFICAS.....	48
APÊNDICE.....	53

1. INTRODUÇÃO

A educação brasileira enfrenta desafios persistentes, refletidos em seu desempenho abaixo da média global nos principais domínios de avaliação: leitura, matemática e ciências. Essa defasagem é evidenciada pelos resultados do *Programme for International Student Assessment* (PISA) de 2022, uma iniciativa da Organização para a Cooperação e Desenvolvimento Econômico (OCDE) que avalia comparativamente o desempenho educacional de estudantes em diversos países (OCDE,2025).

Além disso, um instrumento relevante para a análise do desempenho dos estudantes brasileiros é o Exame Nacional do Ensino Médio (ENEM). A interpretação dos resultados desse exame permite identificar com maior precisão as áreas do conhecimento nas quais os alunos apresentam maiores dificuldades. Esse diagnóstico é fundamental, pois o desenvolvimento de políticas públicas eficazes para a melhoria da qualidade da educação exige a compreensão detalhada dos principais pontos críticos do sistema educacional.

Realizado desde 1998, o ENEM tem se consolidado como uma importante fonte de dados para a avaliação do sistema educacional brasileiro. Diversos estudos vêm utilizando suas informações para analisar o desempenho dos estudantes ao longo dos anos, especialmente no que se refere à influência de fatores socioeconômicos nas notas obtidas pelos participantes. Conforme destacado por Barros, Silva e Adeodato(2022), essas análises permitem identificar desigualdades educacionais e compreender como o contexto social e econômico impacta o rendimento escolar, tornando o ENEM uma base rica para estudos sobre a realidade educacional em um país tão extenso e diverso como o Brasil.

A aplicação do processo de Descoberta de Conhecimento em Bases de Dados (KDD) na área educacional permite a criação de modelos preditivos. Esses modelos, ao utilizarem técnicas de classificação, podem antecipar comportamentos dos alunos, fornecendo *insights* valiosos para intervenções pedagógicas e para a otimização dos processos de ensino (Comendador et al., 2016)."

O uso de técnicas de KDD e mineração de dados (*data mining*) já vem sendo aplicado há alguns anos aos microdados do ENEM. Um exemplo disso pode ser observado em Bravin et al. (2019), que realizaram uma análise dos dados da edição de 2015 do exame. Naquele estudo, os autores investigaram a influência de fatores socioeconômicos no desempenho dos estudantes, bem como as disparidades entre alunos de escolas públicas e privadas.

Já este estudo tem como objetivo identificar os tópicos de matemática nos quais os estudantes apresentam maior defasagem de conhecimento. Para tanto, será desenvolvido um algoritmo de classificação, implementado em linguagem Python, com base nos dados disponibilizados pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), referentes ao ENEM de 2023. Serão utilizados tanto os microdados de desempenho dos estudantes quanto as questões aplicadas na prova daquele ano, permitindo uma análise detalhada do desempenho por conteúdo.

1.1 PROBLEMA DE PESQUISA

A educação brasileira vem apresentando, ao longo dos anos, desempenho insatisfatório em avaliações de larga escala, especialmente quando comparada a indicadores internacionais. Esse cenário evidencia a necessidade de compreender, de forma mais precisa, quais áreas do conhecimento concentram as maiores dificuldades de aprendizagem, de modo a subsidiar intervenções pedagógicas mais eficazes. Nesse contexto, técnicas de Análise de Dados configuram-se como ferramentas relevantes para a realização de diagnósticos educacionais mais aprofundados e sistemáticos.

O Exame Nacional do Ensino Médio (ENEM), aplicado anualmente, além de desempenhar papel central no acesso ao ensino superior, constitui uma importante fonte de dados para avaliação do desempenho dos estudantes concluintes da educação básica. Entre as áreas avaliadas, a Matemática destaca-se historicamente pelos baixos índices de desempenho, indicando a presença de lacunas significativas na aprendizagem.

Diante disso, coloca-se o seguinte problema de pesquisa: como classificar as questões do ENEM de acordo com as competências específicas relacionadas à Matemática, de modo a apoiar a análise do desempenho dos estudantes e a identificação de conteúdos de maior dificuldade?

1.2 JUSTIFICATIVA

Este trabalho justifica-se pela possibilidade de analisar o desempenho dos estudantes com deficiência visual de forma mais detalhada, a partir da organização das questões segundo cada disciplina avaliada. Essa abordagem permite identificar em quais áreas do conhecimento os participantes que realizam a prova laranja apresentam maiores defasagens. Por meio da comparação entre as respostas desses estudantes e o gabarito oficial, torna-se viável mapear as dificuldades específicas enfrentadas por esse público. Com base nesses achados, poderão ser propostas estratégias pedagógicas mais eficazes, voltadas à redução dessas defasagens e à promoção de um processo de aprendizagem mais inclusivo e equitativo.

1.3 OBJETIVOS

1.3.1 Objetivo Geral

Desenvolver um método para classificar as questões do Exame Nacional do Ensino Médio (ENEM) de acordo com as competências específicas de Matemática, utilizando técnicas de Análise de Dados e Processamento de Linguagem Natural, de modo a apoiar a análise do desempenho dos estudantes e a identificação de áreas de maior dificuldade.

1.3.2 Objetivos Específicos

- Realizar o levantamento e o tratamento dos microdados do ENEM disponibilizados pelo INEP.
- Identificar e organizar as competências e habilidades de Matemática avaliadas no ENEM.

- Implementar técnicas de Processamento de Linguagem Natural para representar textualmente as questões da prova.
- Aplicar e comparar diferentes algoritmos de classificação automática de texto para categorização das questões.
- Avaliar o desempenho dos modelos de classificação quanto à precisão e ao equilíbrio na distribuição das competências identificadas.
- Validar o modelo proposto por meio da comparação com gabaritos e referências oficiais.
- Analisar os resultados obtidos, visando identificar padrões de dificuldade nas competências matemáticas avaliadas.

1.4 ORGANIZAÇÃO DO TRABALHO

O trabalho está organizado em capítulos, sendo eles: Introdução, Referencial Teórico, Metodologias e Tecnologias, Resultados, Conclusão, Referências e Apêndice.

Na Introdução, são apresentados a contextualização do tema, os objetivos e a justificativa do trabalho. O Referencial Teórico aborda os materiais utilizados e a fundamentação teórica que embasa a pesquisa.

No capítulo de Metodologias e Tecnologias, são descritas as ferramentas utilizadas, a metodologia adotada, o tratamento dos dados e o processo de criação dos algoritmos.

Em Resultados, são apresentados os resultados obtidos, juntamente com a análise do algoritmo e os dados do ENEM.

A Conclusão reúne as considerações finais do trabalho, bem como sugestões para trabalhos futuros. Por fim, são apresentadas as referências, com a relação dos trabalhos utilizados como base para a pesquisa, e o Apêndice, contendo materiais complementares.

2 REFERENCIAL TEÓRICO

2.1 MICRODADOS ENEM

Os microdados do Enem são o menor nível de desagregação de dados recolhidos por meio do exame. Eles atendem a demanda por informações específicas ao disponibilizar as provas, os gabaritos, as informações sobre os itens, as notas e o questionário respondido pelos inscritos no Enem (INEP, 2024). Assim escolhemos os dados referentes às provas de 2023, sendo a última atualização corrente na data de 24/07/2024.

2.1.1 ESTRUTURA ORGANIZACIONAL DAS PROVAS DO ENEM

O ENEM é composto por uma prova de múltipla escolha com cinco alternativas por questão, abrangendo conteúdos relacionados ao ensino médio. A avaliação é aplicada em dois dias e contém um total de 180 questões, distribuídas em quatro áreas de conhecimento: Linguagens, Códigos e suas Tecnologias; Ciências Humanas e suas Tecnologias; Ciências da Natureza e suas Tecnologias; e Matemática e suas Tecnologias(ENEM, 2025).

As provas são disponibilizadas em diferentes cores — amarelo, azul, branco, verde e laranja — com o intuito de organizar diferentes versões da mesma avaliação . A versão laranja é especialmente destinada a participantes com deficiência visual, apresentando transcrições descritivas de imagens ou versões em braile. É importante ressaltar que a variação de cores não implica em alteração no nível de dificuldade das questões, apenas na ordem em que são apresentadas (INEP,2025)

No contexto deste estudo, a escolha pelo uso do caderno laranja justifica-se pelo fato de suas questões conterem descrições textuais de imagens, o que facilita a análise automatizada dos dados. Isso elimina a necessidade de aplicar algoritmos de processamento de imagem mais complexos, permitindo o foco na análise semântica e estrutural dos enunciados.

2.2 DESCRITORES

O ENEM disponibiliza descritores que servem como base orientadora para a elaboração das questões do exame, assim eles descrevem as habilidades e conhecimentos que são avaliados em cada área do conhecimento da prova. A partir dessa base, é possível identificar quais são as disciplinas abordadas na prova de Matemática. Após a leitura da Matriz de Referência, observamos que a prova de Matemática está estruturada em sete competências, que abrangem diferentes áreas do conhecimento matemático. A seguir, apresenta-se a descrição de cada competência da Matriz de Referência (MATRIZ DE REFERÊNCIA ENEM, 2025):

Competência 1 – Significado Numérico: Aplicar de forma prática os números naturais, inteiros, racionais e reais em contextos sociais e do cotidiano, avaliando resultados, reconhecendo padrões e resolvendo problemas com base em raciocínio numérico.

Competência 2 – Espaço e Forma: Compreender e utilizar noções de geometria para interpretar, representar e intervir no espaço e nas formas, reconhecendo propriedades, formas planas e espaciais, além de relações métricas.

Competência 3 – Grandezas e Medidas: Utilizar medidas, escalas, estimativas, unidades e conversões para resolver problemas do cotidiano, avaliando relações de proporcionalidade e transformações entre grandezas.

Competência 4 – Tratamento da Informação: Interpretar e analisar informações expressas em gráficos, tabelas, diagramas e outras representações estatísticas, utilizando conceitos de estatística e probabilidade para tomar decisões fundamentadas.

Competência 5 – Argumentação Quantitativa: Elaborar argumentos consistentes com base em dados quantitativos, interpretando informações numéricas e avaliando a veracidade de afirmações apoiadas por cálculos ou estimativas.

Competência 6 – Modelagem Matemática: Compreender e utilizar modelos matemáticos para representar e resolver situações-problema, estabelecendo

relações entre diferentes elementos da realidade por meio de expressões, equações e fórmulas.

Competência 7 – Raciocínio Algébrico: Utilizar a linguagem algébrica para representar e resolver problemas, compreender o comportamento de funções, analisar equações e desigualdades, e identificar relações entre variáveis.

2.3 DADOS

2.3.1 DADOS ABERTOS

Dados abertos referem-se a conjuntos de informações disponibilizados sem restrições e com transparência para o público, possibilitando sua reutilização para pesquisas científicas e desenvolvimento de políticas públicas. Essas bases de dados possuem quatro principais características: disponibilidade de acesso, reutilização, redistribuição e participação universal (Júnior, 2024).

2.3.2 MICRODADOS ENEM

O INEP disponibiliza as provas e os dados do ENEM realizados no ano anterior, incluindo informações sobre as questões aplicadas e dados dos participantes, como raça, escolaridade, situação financeira, entre outros. Ao mesmo tempo, são omitidos dados que possam permitir a identificação dos candidatos, como nome ou CPF. Também são divulgadas as diferentes versões da prova, organizadas por cor e por área do conhecimento, o que torna esse conjunto uma excelente fonte para análises educacionais e estatísticas.

Os dados disponibilizados na plataforma de dados abertos, após serem baixados, são organizados nas seguintes categorias: Dados, Dicionários, Inputs, Documentos Técnicos, Provas e Gabaritos.

Na categoria Dados, encontram-se as informações referentes aos participantes, incluindo dados étnicos e de localização, além das notas e respostas. Esses dados são organizados em planilhas e divididos em diferentes categorias, com foco principal nas informações dos alunos.

A seção Dicionários apresenta a descrição das informações disponíveis na categoria Dados, especificando o significado de cada variável e indicando a qual categoria cada dado pertence.

Em Inputs, são disponibilizados exemplos de uso de APIs e requisições que podem ser realizadas com os dados do ENEM, auxiliando na integração e manipulação dessas informações.

A categoria Documentos Técnicos reúne materiais auxiliares relacionados às provas, como guias, manuais e regras do exame.

Por fim, a seção Provas e Gabaritos contém todas as provas em formato PDF, além dos gabaritos oficiais, incluindo também a prova na versão laranja em formato TXT.

2.4 ANÁLISE DE DADOS

A análise de dados é um processo cujo principal objetivo é transformar informações brutas e dados numéricos em *insights* relevantes, que auxiliem na descoberta de conhecimento e na tomada de decisões mais precisas. Para isso, são frequentemente utilizados métodos como o aprendizado de máquina e a mineração de dados, que permitem identificar padrões ocultos e gerar informações estratégicas a partir de grandes volumes de dados (BELINI; ATAIDE; LOCHTER, 2024).

A análise de dados tem se mostrado uma ferramenta essencial para a melhoria da qualidade da educação, permitindo uma compreensão mais aprofundada do desempenho dos estudantes, das práticas pedagógicas e das políticas educacionais. Ao utilizar métodos de mineração de dados e aprendizado de máquina, é possível identificar padrões de aprendizagem, prever evasão escolar, personalizar o ensino e promover intervenções mais eficazes. De acordo com o artigo de Romero e Ventura (2010), a área de *Educational Data Mining* (EDM) tem crescido significativamente como resposta à necessidade de extrair conhecimento útil a partir dos grandes volumes de dados gerados em ambientes educacionais, auxiliando gestores e educadores na tomada de decisões baseadas em evidências. Dessa forma, a análise de dados não apenas potencializa a gestão educacional, mas também contribui para uma educação mais equitativa e centrada no estudante.

2.4.1 TÉCNICAS DE ANÁLISE

MODELOS DE ANÁLISE CLASSIFICATÓRIA

Os modelos de análise classificatória são utilizados para atribuir categorias ou rótulos a dados com base em características observadas. Diferentemente dos modelos preditivos que estimam valores numéricos contínuos, os classificatórios lidam com variáveis dependentes categóricas, como “sim” ou “não”, “aprovado” ou “reprovado”, entre outras. Esses modelos são amplamente empregados em áreas como reconhecimento de padrões, diagnóstico médico, detecção de fraudes e segmentação de clientes (HAN; KAMBER; PEI, 2012).

Entre os principais algoritmos de classificação destacam-se a regressão logística, árvores de decisão, k-vizinhos mais próximos (KNN), máquinas de vetor de suporte (SVM) e redes neurais. A escolha do modelo ideal depende da natureza dos dados, da quantidade de atributos e da complexidade da tarefa. O desempenho dos modelos classificatórios é geralmente avaliado por métricas como acurácia, precisão, *recall* e a matriz de confusão, o que permite ajustes finos e melhoria contínua dos resultados.

2.5 ALGORITMOS DE CLASSIFICAÇÃO TEXTUAL

A classificação de texto concentra-se especificamente na categorização e organização de dados de texto para facilitar o gerenciamento e a análise. Essas técnicas alavancam processamento de linguagem natural, aprendizado de máquina, e mineração de dados para extrair padrões significativos e categorizar dados de texto, transformando assim texto não estruturado em *insights* estruturados e acionáveis. As aplicações destes métodos são cruciais em áreas como classificação de documentos, onde os textos são categorizados com base em seu conteúdo, e recuperação de informações, que envolve a pesquisa em grandes conjuntos de dados para encontrar documentos relevantes. Além disso, a classificação do texto é fundamental para a análise de sentimento, detecção de *spam*, e modelagem de tópicos, permitindo melhor compreensão e utilização de dados de texto em vários campos (Taha Kamal, 2024).

a) CLASSIFICAÇÃO SIMPLES

A classificação simples consiste em um procedimento determinístico baseado na correspondência direta entre termos presentes no texto e conjuntos previamente definidos de palavras associadas às categorias de interesse. Trata-se de um modelo essencialmente baseado em regras, no qual a decisão é tomada pela presença ou ausência de indicadores textuais específicos, sem ponderações adicionais. Essa abordagem é frequentemente descrita na literatura introdutória de recuperação de informação e processamento textual (Manning et al., 2008) .

b) CLASSIFICAÇÃO POR PALAVRAS-CHAVE COM PESOS

A classificação por palavras-chave com pesos representa uma evolução da abordagem anterior, ao atribuir diferentes valores de importância aos termos que compõem o vocabulário relevante. Dessa forma, palavras consideradas mais representativas da classe exercem influência maior no processo decisório, permitindo maior sensibilidade às nuances do texto. Esse esquema de ponderação é amplamente discutido na literatura de recuperação de informação (Manning et al., 2008) .

c) TF-IDF

O método TF-IDF (*Term Frequency – Inverse Document Frequency*) estabelece um peso para cada termo combinando a sua frequência no documento com a sua raridade no conjunto total de textos. Assim, termos comuns recebem menor relevância, enquanto termos raros e informativos passam a ter maior impacto nas decisões de classificação e ranqueamento. Essa técnica tornou-se um dos pilares dos sistemas de busca e análise textual (Salton e Buckley, 1988).

d) ALGORITMO DE *RANKING* DE PROXIMIDADE LEXICAL - BM25

O Algoritmo de *Ranking* de Proximidade Lexical BM25 insere-se na família de modelos probabilísticos de relevância e calcula um escore de similaridade entre texto e consulta, considerando a saturação da frequência de termos e a normalização pelo comprimento do documento. Tal formulação proporciona um equilíbrio entre frequência, raridade e distribuição dos termos, consolidando o BM25

como um dos algoritmos mais eficazes para ranqueamento lexical (Robertson e Zaragoza, 2009) .

2.6 FERRAMENTAS DE ANÁLISE

Existem diversas linguagens de programação desenvolvidas para os mais variados propósitos. A análise de dados é uma área amplamente consolidada no mercado, o que levou ao surgimento e à consolidação de linguagens especificamente voltadas para esse tipo de aplicação. Nesse contexto, destacam-se, conforme apresentado a seguir, algumas das principais linguagens utilizadas nessa área.

2.6.1 LINGUAGENS DE PROGRAMAÇÃO

a) Python

A linguagem de programação Python é interpretada, interativa e orientada a objetos. Seu desenvolvimento teve início no final da década de 1980, no Instituto Nacional de Pesquisa em Matemática e Ciência da Computação, na Holanda, sob a liderança de Guido van Rossum. Segundo o próprio criador, Python pode ser compreendida tanto como uma linguagem de *script* de alto nível quanto como uma linguagem de programação tradicional que valoriza a interatividade. Isso se deve ao fato de que ela compartilha características comuns a linguagens de *script*, ao mesmo tempo em que incorpora elementos presentes em linguagens mais estruturadas e convencionais (VAN ROSSUM, 2003).

b) Linguagem de Programação R

A linguagem de programação R é voltada principalmente para a análise estatística, mineração de dados e visualização gráfica. Seu desenvolvimento teve início na década de 1990 pelos estatísticos Ross Ihaka e Robert Gentleman, na Universidade de Auckland, na Nova Zelândia. R é uma linguagem interpretada, funcional e orientada a objetos, amplamente utilizada nas áreas de estatística, ciência de dados, bioinformática e economia (R CORE TEAM, 2024).

Uma das principais características do R é sua vasta coleção de pacotes voltados para análise de dados, além de sua capacidade de produzir visualizações gráficas

de alta qualidade. Por ser uma linguagem livre e de código aberto, R tem uma comunidade ativa que constantemente contribui com melhorias, pacotes e documentação, tornando-a uma ferramenta poderosa tanto no meio acadêmico quanto no mercado profissional.

2.6.2 AMBIENTES DE ANÁLISES

Neste trabalho, optou-se pela utilização de um ambiente *on-line*, de modo a não depender de um computador físico específico, mas sim de uma infraestrutura em nuvem para a realização da análise de dados e o desenvolvimento dos algoritmos.

a) Google Colab

O Google Colab é um serviço baseado na plataforma Jupyter Notebook, que permite a execução de código em um ambiente hospedado na nuvem, sem a necessidade de instalação ou configuração local. Ele oferece acesso gratuito a recursos computacionais avançados, como GPUs e TPUs, sendo amplamente utilizado em atividades relacionadas ao aprendizado de máquina, ciência de dados e ensino de programação (GOOGLE, 2024).

Por ser acessível diretamente pelo navegador, o Colab possibilita o desenvolvimento de projetos em diferentes dispositivos e locais, promovendo maior flexibilidade para o usuário. Além disso, sua interface intuitiva e integração com o Google Drive facilitam o uso por pessoas com conhecimentos básicos em programação, o que contribui para sua popularidade como uma ferramenta eficiente e acessível.

B) Replit

O Replit é uma plataforma *online* que permite a criação, execução e compartilhamento de código diretamente do navegador, sem a necessidade de instalar *softwares* no computador. Ele suporta diversas linguagens de programação, como Python, JavaScript, C++, entre outras, e oferece um ambiente de desenvolvimento completo e colaborativo, acessível de qualquer lugar com conexão à internet (REPLIT, 2024).

Sua interface amigável e a possibilidade de edição em tempo real por múltiplos usuários tornam o Replit uma excelente escolha para projetos educacionais, trabalhos em equipe e aprendizado inicial de programação. Além disso, recursos como hospedagem de aplicações *web*, terminais integrados e gerenciamento de pacotes tornam a ferramenta poderosa mesmo para usuários mais avançados, consolidando o Replit como uma alternativa prática, acessível e versátil no ensino e desenvolvimento de *software*.

2.7 TRABALHOS RELACIONADOS

Nos últimos 26 anos, o ENEM tem criado uma base robusta de dados, reunindo informações detalhadas sobre os alunos, seus resultados e fatores socioeconômicos, além dos dados das provas aplicadas. Essa riqueza e vastidão de informações tornam o ENEM uma fonte valiosa para pesquisas acadêmicas e análises educacionais. Ao longo dos anos, diversos pesquisadores e autores têm explorado essa base de dados para investigar padrões de desempenho, desigualdades regionais, impacto de variáveis socioeconômicas e tendências educacionais, como pode se ver na Análise de dados do ENADE e ENEM : uma revisão sistemática da literatura, que mostra vários artigos publicados durante esse período e análises sobre como diferentes fatores impactam na nota final do aluno (Lima et al, 2019).

A partir das análises dos dados produzidos pela aplicação desses exames, é possível observar o desempenho tanto do estudante quanto das instituições e, assim, calcular indicadores de qualidade que, dentro de um contexto, oportunizarão decisões de melhoria do processo de ensino e aprendizagem. Este trabalho apresenta uma Revisão Sistemática da Literatura (RSL), com o intuito de identificar os objetivos e tipos de análises que têm sido feitas usando os dados dos exames. A revisão mostrou que essas análises são limitadas, geralmente usando estatística descritiva, e focam, principalmente, em dados socioeconômicos e notas dos exames.

No estudo "Mineração de Dados Abertos – ENEM 2018" (Barcellos, 2018), observa-se de forma específica como fatores como acesso à internet, nível de alfabetização dos pais e renda familiar impactam diretamente o desempenho dos

estudantes nas provas. Utilizando algoritmos de clusterização, o estudo evidencia como cada uma dessas variáveis influencia as notas finais, permitindo identificar grupos de estudantes com características socioeconômicas semelhantes e desempenho correlato. Esse trabalho demonstra que, já em 2018, os dados abertos disponibilizados pelo INEP se mostraram uma fonte eficiente para aplicações de mineração de dados, possibilitando análises relevantes sobre o contexto educacional brasileiro.

No estudo "Análise de Dados Históricos do ENEM 2015 a 2019 utilizando Python e Pandas", são examinados os microdados do ENEM ao longo de quatro anos, utilizando ferramentas que também serão aplicadas neste trabalho, como Python e bibliotecas de ciência de dados (especialmente Pandas). Por meio de mineração de dados, o estudo extrai e compara notas dos participantes entre 2015 e 2019, considerando fatores como sexo, região, desempenho por competência da prova e outros aspectos que influenciam o resultado final. Essa abordagem permite não apenas observar diferenças regionais e sociais ao longo de uma série histórica, mas também identificar fatores que contribuem para a ausência de candidatos e variações no desempenho, oferecendo informações relevantes sobre a educação no Brasil (Nakazone et al., 2021).

3 TECNOLOGIAS E METODOLOGIA

3.1 TECNOLOGIAS

Para o desenvolvimento do algoritmo, será utilizado o ambiente virtual Google Collaboratory. Essa plataforma permite a execução dos códigos diretamente na nuvem, utilizando a linguagem Python, sem a necessidade de configurações locais. Além disso, o Google Colab oferece suporte nativo a diversas bibliotecas de aprendizado de máquina, o que facilita a implementação, o teste e a análise dos modelos desenvolvidos.

A linguagem de programação que será adotada é o Python, devido à sua ampla utilização na análise de dados e aprendizado de máquina, sua sintaxe acessível e vasta comunidade garantem suporte contínuo e atualizações frequentes.

As bibliotecas do Python são numerosas e oferecem uma ampla gama de recursos para os desenvolvedores como, por exemplo, a biblioteca Pandas. Ela inclui módulos embutidos, escritos em C, que proporcionam acesso a funcionalidades do sistema, como entrada e saída de arquivos, que normalmente seriam inacessíveis diretamente pela linguagem. Além disso, conta com módulos escritos em Python que fornecem soluções padronizadas para problemas comuns enfrentados na programação do dia a dia. Muitos desses módulos são projetados com foco na portabilidade, permitindo que os programas em Python funcionem em diferentes sistemas operacionais por meio de APIs independentes de plataforma (PYTHON SOFTWARE FOUNDATION, 2024).

Com a possível utilização dos módulos Numpy, Math e SciPy que disponibilizam diversas funções e operações matemáticas envolvendo vetores, matrizes, cálculos de dispersão, medidas de posição e centralidade, entre outras funcionalidades

A biblioteca Pandas será utilizada para manipulação e análise dos dados, permitindo a leitura, filtragem e transformação do conjunto de dados de forma eficiente. O Data Frame, estrutura de dados fornecida pelo Pandas, será utilizado

para armazenar e processar os registros extraídos da base histórica dos microdados do enem no ano de 2023.

Outra biblioteca a ser utilizada é a Matplotlib que permitirá visualização gráfica dos dados, possibilitando a criação de histogramas, gráficos de dispersão e outras representações visuais que auxiliem na interpretação dos resultados.

3.2 METODOLOGIAS

3.2.1 AQUISIÇÃO DOS DADOS

Os dados empregados nesta pesquisa são provenientes das bases públicas disponibilizadas pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (INEP), com recorte temporal referente ao ano de 2023. O conjunto de dados contempla não apenas os cadernos de prova do Exame Nacional do Ensino Médio (ENEM), mas também os microdados de desempenho individual dos participantes, incluindo a identificação de acertos e erros por questão.

Cada registro da base reúne informações relativas às respostas fornecidas pelo participante, ao tipo de caderno de prova utilizado, ao respectivo gabarito oficial e a variáveis contextuais de natureza socioeconômica e demográfica, tais como cor/raça, faixa etária, renda e idade, entre outras consideradas relevantes para a análise.

A base de resultados individuais é composta por 3.933.955 registros, dos quais 2.678.264 correspondem a participantes presentes em todos os dias de aplicação do exame. Com o objetivo de delimitar a amostra e garantir maior homogeneidade dos dados analisados, adotou-se como critério de inclusão apenas os participantes que realizaram a prova de cor laranja em todas as modalidades, totalizando 783 estudantes. Foram excluídos da análise os registros de participantes ausentes em qualquer um dos dias de aplicação.

Adicionalmente, o estudo restringe-se às provas aplicadas no segundo dia do exame, que abrangem as áreas de Ciências da Natureza e suas Tecnologias e Matemática e suas Tecnologias, por serem os componentes curriculares de interesse para a investigação proposta.

3.2.2 LIMPEZA DOS DADOS

Os dados relacionados às provas do ENEM, disponibilizados por meio da plataforma de dados abertos, não exigem um tratamento altamente específico em sua estrutura original. Sendo o único tratamento necessário para a análise léxica das questões a padronização dos dados, realizou-se a conversão dos arquivos no formato .txt, disponibilizados pela fonte original, para o formato .csv. Esse arquivo foi estruturado inicialmente em três colunas: número da questão, corpo da questão e resposta. Posteriormente, foi adicionada uma quarta coluna contendo o nome da respectiva matéria à qual cada questão pertence. Essa etapa será descrita com maior detalhamento ao longo do desenvolvimento do algoritmo.

3.2.3 GABARITO

O INEP não disponibiliza um gabarito oficial que relacione as questões do ENEM aos seus respectivos descritores. Dessa forma, para a comparação e validação dos algoritmos desenvolvidos, tornou-se necessário identificar a qual categoria cada questão pertence.

Para isso, foi realizada uma pesquisa em sites de cursinhos e escolas preparatórias, nos quais foi possível encontrar a categorização das questões por descritores (ZBS,2026). No entanto, esse tipo de classificação estava disponível apenas para uma versão específica da prova, a prova amarela. Como as diferentes cores de prova possuem o mesmo conteúdo, variando apenas a ordem das questões, tornou-se possível utilizar essa categorização como base para a construção de um gabarito próprio.

Assim, cada questão presente na plataforma do cursinho foi comparada com o material disponibilizado pelo INEP, especificamente com a prova na versão laranja. A partir dessa comparação, foi elaborada uma lista contendo a correspondência entre os números das questões da prova amarela e seus equivalentes na prova laranja, juntamente com seus respectivos descritores.

Com isso, foi possível construir um gabarito categorizado, que foi utilizado tanto na análise do desempenho dos alunos quanto na avaliação da eficiência dos algoritmos desenvolvidos.

3.2.4 DESENVOLVIMENTO

Com os dados devidamente padronizados, tornou-se possível iniciar a avaliação de diferentes algoritmos de classificação léxica. Como base experimental, foram pré-selecionados quatro algoritmos de classificação: classificação simples por repetição de palavras, *Term Frequency* (TF), *Term Frequency–Inverse Document Frequency* (TF-IDF) e Word2Vec. Além disso, foi implementada uma variação do algoritmo de *Term Frequency* utilizando técnicas de Inteligência Artificial, com o objetivo de obter uma base comparativa que evidencie os motivos pelos quais a utilização de IA não se mostra a abordagem mais adequada para este caso específico.

Os algoritmos foram projetados para avaliar as questões com base nos descritores do ENEM, classificando cada questão em um dos sete descritores definidos. Dessa forma, os classificadores distribuem automaticamente cada questão em uma dessas categorias, permitindo a realização de uma pré-análise dos resultados. Essa etapa é fundamental para que, posteriormente, seja possível definir qual abordagem deverá ser priorizada e aprofundada ao longo do desenvolvimento do trabalho.

Para isso, os algoritmos foram implementados utilizando a linguagem Python. A lógica básica do processo consiste na leitura do arquivo .csv padronizado e na adição de uma resposta em uma coluna específica correspondente à questão analisada. Cada algoritmo processa o corpo da questão e retorna a matéria ou descritor que julga mais adequado para aquela questão.

A partir dessa classificação automática, os resultados obtidos podem ser comparados com a classificação real de cada questão, possibilitando a avaliação das métricas de acurácia e precisão de cada algoritmo. Com base nessa análise comparativa, torna-se viável selecionar o algoritmo mais apropriado, que será posteriormente aprimorado e desenvolvido com o objetivo de alcançar resultados mais consistentes e confiáveis.

3.2.5 ESCOLHA DOS ALGORITMOS

A partir dos algoritmos previamente definidos, as questões do Exame Nacional do Ensino Médio (ENEM) foram estruturadas em um arquivo no formato CSV, composto por três colunas principais: número, correspondente à numeração da questão no caderno de prova de cor laranja; corpo, referente ao enunciado da questão; e respostas, que representam as alternativas assinaladas pelo participante em um sistema de múltipla escolha. Posteriormente, esse conjunto de dados foi integrado ao gabarito oficial, obtido a partir da base disponibilizada pelo INEP.

Adicionalmente, com base nos descritores associados a cada item, foi elaborado um segundo arquivo CSV contendo um índice de correspondência entre as questões e suas respectivas disciplinas. Para as análises textuais e para a aplicação dos algoritmos de classificação, utilizou-se exclusivamente o conteúdo presente no campo corpo das questões, desconsiderando-se informações adicionais que pudessem introduzir vieses no processamento.

Com a base de dados consolidada, procedeu-se à implementação dos algoritmos propostos neste estudo. Como estratégia de comparação metodológica e com o intuito de fundamentar a opção por abordagens menos complexas, também foi desenvolvido um modelo baseado em TF (*Term Frequency*), utilizando a biblioteca scikit-learn. Esse modelo foi empregado como referência comparativa, contribuindo para a análise crítica dos resultados e para a justificativa das escolhas metodológicas adotadas, especialmente no que se refere à não utilização de técnicas mais robustas de Inteligência Artificial e de Aprendizado de Máquina.

Para assegurar uma avaliação consistente entre os diferentes algoritmos, adotou-se como conjunto de teste as 45 questões de Matemática do ENEM 2023. As métricas de desempenho consideradas foram a precisão geral e a precisão por disciplina, considerando as sete áreas temáticas definidas no estudo. Além disso, foi utilizado o mesmo vocabulário por área temática em todos os modelos, a fim de garantir condições equitativas de comparação. Todos os algoritmos foram implementados em um mesmo ambiente computacional, utilizando o Google Colab, e avaliados sob as mesmas métricas, de modo a assegurar a consistência metodológica e a

reprodutibilidade dos resultados. A seguir são descritos os algoritmos implementados:

Algoritmo 1 – Regras Simples:

Classificador textual básico que avalia se o texto de entrada contém palavras associadas a cada disciplina. A classificação é realizada com base na quantidade de ocorrências dessas palavras em cada vocabulário disciplinar.

Algoritmo 2 – TF (*Term Frequency*):

Assim como o modelo de regras simples, esse algoritmo considera a frequência das palavras presentes no vocabulário. Entretanto, o texto é vetorizado, transformando cada termo em um valor numérico, o que possibilita o cálculo da classificação final de cada questão de forma mais estruturada.

Algoritmo 3 – TF (Scikit-learn):

Variante do modelo TF implementada por meio da biblioteca Scikit-learn, utilizando uma abordagem básica de aprendizado supervisionado. O modelo é treinado com um conjunto reduzido de dados e aplicado à tarefa de classificação das questões.

Algoritmo 4 – TF-IDF (*Term Frequency – Inverse Document Frequency*):

Extensão do modelo TF, incorporando o fator IDF, responsável por corrigir o peso das palavras. Além de considerar a frequência dos termos, o algoritmo atribui maior relevância a palavras mais discriminativas, reduzindo a influência de termos muito comuns.

Algoritmo 5 – Word2Vec:

Modelo baseado em representações vetoriais densas, no qual as palavras são mapeadas de acordo com relações semânticas, permitindo uma análise mais contextual do texto.

3.2.6 VOCABULÁRIO

O vocabulário constitui um elemento fundamental para o funcionamento dos modelos de classificação, uma vez que é por meio dele que os algoritmos determinam a qual matéria cada questão pertence. De forma geral, ao identificar no corpo da questão a ocorrência de um termo presente no vocabulário, o modelo

atribui uma pontuação à disciplina associada a esse termo. Essa descrição representa uma visão geral do funcionamento dos classificadores, sendo mais evidente no modelo baseado em regras simples, mas ainda aplicável, em diferentes graus, aos demais modelos avaliados.

Nesse contexto, a qualidade do vocabulário exerce influência direta sobre a precisão do modelo, visto que um conjunto de termos bem definido contribui significativamente para uma classificação mais assertiva. Para a construção do vocabulário inicial, foram extraídas palavras-chave das questões do ENEM, organizadas de acordo com cada disciplina, as quais foram utilizadas como base para a etapa de testes dos algoritmos.

Dessa forma, o vocabulário inicial utilizado para a seleção dos algoritmos foi construído com base nos descritores e em palavras que aparecem com frequência nas diferentes disciplinas. Essa abordagem resultou em um vocabulário mais generalista, adequado para a criação e avaliação do primeiro conjunto de algoritmos.

Esse vocabulário passou por uma otimização inicial, com o objetivo de alcançar uma precisão geral comparável entre os modelos avaliados, porém sem um refinamento específico voltado exclusivamente às questões do ENEM. Com isso, foi possível estabelecer uma base sólida e neutra para a comparação dos algoritmos, garantindo que os resultados obtidos refletissem principalmente as características de cada método, e não ajustes excessivamente direcionados ao conjunto de dados. O Quadro 1 mostra o vocabulário inicial usado nos testes.

Quadro 1: vocabulário inicial.

MATÉRIA	PALAVRAS
Aritmética	"número", "numeral", "natural", "inteiro", "real", "decimal", "fração", "soma", "subtração", "multiplicação", "divisão", "adicionar", "subtrair", "multiplicar", "dividir", "porcentagem", "percentual", "aumento", "desconto", "juros", "simples", "composto", "proporção", "razão", "regra", "três", "conversão", "cálculo", "aritmética", "valor", "quantidade", "total", "diferença", "equivalente", "custo", "preço", "tarifa"

MATÉRIA	PALAVRAS
Geometria	"ângulo", "área", "volume", "perímetro", "triângulo", "quadrado", "retângulo", "círculo", "circunferência", "raio", "diâmetro", "polígono", "paralelo", "perpendicular", "geométrico", "plano", "espacial", "pirâmide", "cilindro", "cone", "esfera", "altura", "base", "lados", "teorema", "pitágoras", "geometria", "distância", "comprimento", "largura", "coordenada", "cartesiano", "arestas", "vértices", "malha", "projeção"
Grandezas e Medidas	"metro", "centímetro", "quilômetro", "litro", "mililitro", "quilo", "grama", "massa", "volume", "distância", "tempo", "velocidade", "aceleração", "densidade", "capacidade", "temperatura", "pressão", "escala", "medida", "conversão", "grandeza", "unidade", "taxa", "sensor", "equipamento", "régua", "balança"
Proporcionalidade e Variação	"proporcional", "proporção", "razão", "regra de três", "taxa", "variação", "crescimento", "decréscimento", "inversamente", "diretamente", "constante", "linear", "percentual", "mudança", "evolução", "relação", "comparação", "escala de variação"
Álgebra e Funções	"equação", "função", "expressão", "polinômio", "variável", "x", "y", "incógnita", "sistema", "algébrico", "radical", "expoente", "função afim", "função quadrática", "parábola", "coeficiente", "raiz", "termo", "modelo", "algebraico", "progressão", "aritmética", "geométrica", "exponencial", "logaritmo"
Gráficos e Tabelas	"gráfico", "tabela", "cartesiano", "dados", "eixo", "coluna", "linha", "barra", "pizza", "curva", "diagrama", "dispersão", "legenda", "representação", "função", "taxa", "tendência", "medidas", "informações", "coordenada"
Estatística e Probabilidade	"probabilidade", "média", "mediana", "moda", "amostra", "frequência", "desvio", "variância", "estatística", "percentual", "evento", "experimento", "chance", "população", "intervalo", "estimativa", "distribuição", "tendência", "dados", "análise"

Fonte: gerada pelo autor.

Para facilitar a análise dos dados, os nomes originais dos descritores foram

substituídos por termos sinônimos mais intuitivos e próximos das áreas tradicionalmente utilizadas no ensino de Matemática. Essa adaptação teve como objetivo tornar a interpretação dos resultados mais clara e acessível.

Dessa forma, as equivalências adotadas foram as seguintes: Significado Numérico foi renomeado para Aritmética; Espaço e Forma para Geometria; Grandezas e Medidas manteve a mesma denominação; Tratamento da Informação foi renomeado para Proporcionalidade e Variação; Argumentação Quantitativa para Álgebra e Funções; Modelagem Matemática para Gráficos e Tabelas; e Raciocínio Algébrico para Estatística e Probabilidade.

Essa padronização foi utilizada em todo o trabalho, tanto na organização dos dados quanto na análise dos resultados e na avaliação do desempenho dos algoritmos.

Ressalta-se que esse vocabulário não corresponde à versão final adotada no sistema, mas sim a uma versão preliminar destinada à avaliação comparativa dos algoritmos. Após a seleção do modelo mais adequado, o vocabulário será posteriormente refinado e expandido, com o objetivo de alcançar níveis mais elevados de precisão no algoritmo final.

3.2.7 ESCOLHA DO ALGORITMO FINAL

Após a implementação de todos os algoritmos, foram utilizadas as métricas de precisão total e precisão por disciplina para a avaliação comparativa dos cinco modelos propostos. A Tabela 1 apresenta os resultados obtidos, evidenciando a precisão de acerto alcançada em cada uma das disciplinas analisadas. A última linha da tabela corresponde à precisão final, a qual representa o desempenho global de cada algoritmo considerando o conjunto completo das 45 questões avaliadas.

Tabela 1: comparativos entre a precisão algoritmos de classificação lexical .

Disciplinas	Algoritmo 1	Algoritmo 2	Algoritmo 3	Algoritmo 4	Algoritmo 5
Aritmética	85,71%	42,85%	0,00%	42,86%	28,57%
Estatística	0,00%	83,33%	50,00%	83,33%	50,00%

	Algoritmo 1	Algoritmo 2	Algoritmo 3	Algoritmo 4	Algoritmo 5
Disciplinas					
Probabilidade					
Geometria	33,33%	83,33%	66,66%	100,00%	100,00%
Grandezas e Medidas	0,00%	42,85%	0,00%	28,57%	28,57%
Gráficos e Tabelas	0,00%	20,00%	0,00%	20,00%	20,00%
Proporcionalidade e Variação	0,00%	0,00%	0,00%	50,00%	33,33%
Álgebra e Funções	0,00%	12,50%	12,50%	37,50%	0,00%
Precisão total do algoritmo	17,78%	40,00%	17,78%	51,11%	35,56%

Fonte: gerada pelo autor.

Observa-se que o modelo Algoritmo 4 (TF-IDF) apresentou o melhor desempenho entre os algoritmos avaliados. Esse modelo obteve uma maior precisão média, além de demonstrar uma distribuição mais equilibrada dos resultados, mantendo um valor mínimo de aproximadamente 20% de precisão em todas as disciplinas analisadas.

Em seguida, destacam-se os modelos algoritmo 2 (TF) e algoritmo 5 (Word2Vec), ambos baseados em técnicas de vetorização de texto, os quais também apresentaram resultados superiores quando comparados aos modelos mais simples. Esse desempenho indica que algoritmos mais robustos tendem a oferecer maior precisão na tarefa de classificação léxica.

Por outro lado, o modelo baseado em Algoritmo 1 (regras simples) e o Algoritmo 3 (TF-Scikit-learn) apresentaram desempenhos insatisfatórios. O modelo de regras simples, por sua própria natureza, mostrou elevada dispersão nos resultados, classificando a maioria das questões como pertencentes à disciplina de Álgebra, o que compromete significativamente sua confiabilidade em comparação aos demais algoritmos. Embora esse comportamento possa estar parcialmente relacionado à lógica de implementação, trata-se de um modelo intrinsecamente limitado para tarefas de classificação mais complexas.

Já o algoritmo 3 (TF-Scikit-learn) apresentou limitações decorrentes do tamanho reduzido do conjunto de dados utilizado para treinamento. Considerando que a base de dados empregada contém apenas 45 questões, o processo de treinamento torna-se restrito, dificultando a obtenção de resultados mais expressivos. Ainda assim, é importante ressaltar que, em cenários com conjuntos de dados maiores e modelos de inteligência artificial mais robustos, essa abordagem tende a apresentar desempenho superior.

Diante dos resultados obtidos, o algoritmo 4 (TF-IDF), amplamente utilizado em tarefas de classificação léxica, mostrou-se o candidato mais adequado para a continuidade do trabalho. Seu desempenho consistente e sua precisão satisfatória nos testes realizados justificam sua escolha para a próxima fase do desenvolvimento do projeto.

3.2.8 OTIMIZAÇÃO DO ALGORITMO

A) OTIMIZAÇÃO DO VOCABULÁRIO

Um dos principais fatores para a melhoria do desempenho do modelo está relacionado à construção e ao refinamento do vocabulário. A precisão do vocabulário deve ser cuidadosamente ajustada, uma vez que qualquer alteração nos termos associados a uma determinada disciplina pode impactar diretamente na precisão das demais. Quando o vocabulário é excessivamente ampliado, o modelo tende a perder eficiência, pois ocorre uma redução de sua sensibilidade discriminativa. Por outro lado, um vocabulário muito restrito não fornece informações suficientes para que o modelo consiga identificar com exatidão a disciplina correspondente a cada questão.

Diante desse equilíbrio necessário, adotou-se uma abordagem híbrida para a construção do vocabulário. Além de um vocabulário básico composto por termos gerais, foram incorporadas palavras extraídas da própria base de dados, utilizando questões previamente classificadas de acordo com o gabarito oficial. A partir dessas questões pré-classificadas, foi possível identificar e selecionar palavras-chave relevantes, que foram adicionadas ao vocabulário, ampliando, assim, a precisão do modelo.

Entretanto, essa estratégia pode, em estágios mais avançados, conduzir ao fenômeno de *overfitting*, no qual o modelo se ajusta excessivamente aos dados de treinamento e perde capacidade de generalização. Esse comportamento será analisado de forma mais aprofundada durante a etapa de validação do modelo, conforme discutido nas seções posteriores do trabalho.

O Quadro 2 representa o vocabulário final usado na comparação entre os algoritmos TF-IDF e o TF-IDF melhorado.

QUADRO 2: vocabulário final.

MATÉRIA	PALAVRAS
Aritmética	"número", "contagem", "soma", "algarismo", "inteiro", "par", "ímpar", "primo", "múltiplo", "divisor", "resto", "padrão", "sequência", "lógica", "senha", "código", "calendário", "bissexto", "ciclo", "dias", "semana", "potência", "base", "expoente", "intensidade", "decibel", "decrece", "luminosa", "profundidade"
Geometria	"triângulo", "retângulo", "quadrado", "círculo", "esfera", "cone", "cilindro", "pirâmide", "prisma", "tronco", "ângulo", "grau", "perpendicular", "paralelo", "vértice", "cateto", "hipotenusa", "pitágoras", "raio", "diâmetro", "plano", "reta", "segmento", "ponto", "interseção", "mapa", "norte", "sul", "leste", "oeste", "rosa dos ventos", "projeção", "ortogonal", "vista", "simetria", "
Grandezas e Medidas	"metro", "litro", "grama", "quilograma", "tonelada", "mililitro", "centímetro", "milímetro", "quilômetro", "área", "volume", "capacidade", "massa", "densidade", "comprimento", "largura", "altura", "espessura", "escala", "dimensão", "medida", "tamanho", "reservatório", "cisterna", "nível", "abastecimento", "consumo", "economia", "gasto", "economizar", "eficiência", "vazão", "fluxo", "constante"
Proporcionalidade e Variação	"proporção", "proporcional", "razão", "diretamente", "inversamente", "regra de três", "porcentagem", "percentual", "desconto", "para cada", "a cada", "por minuto", "por hora", "fila", "atendimento", "espera", "caixa", "cliente", "torneira", "ciclo", "interrompe", "molhar", "ensaboar", "roda-gigante", "senoide", "cossenoide", "periódico", "oscila", "carboidrato", "caloria", "dieta", "ingestão", "alimento", "ração", "estoque", "suficiente", "durar", "recalculada"
Álgebra e Funções	"função", "equação", "inequação", "incógnita", "variável", "y em função de x", "expressão", "algébrica", "fórmula", "juros", "compostos", "simples", "capital", "montante", "parcela", "prestação", "entrada", "financiamento", "pagamento", "custo fixo", "custo variável", "lucro", "receita", "venda", "lei de formação", "comportamento", "modelo", "linear", "valor", "preço", "cobrança", "taxa fixa"

MATÉRIA	PALAVRAS
Gráficos e Tabelas	"gráfico", "tabela", "quadro", "figura", "diagrama", "barra", "coluna", "linha", "setor", "pizza", "eixo", "abscissa", "ordenada", "horizontal", "vertical", "tendência", "crescimento", "queda", "estabilidade", "comparar", "superar", "ultrapassar", "maior que", "menor que", "categorias", "legenda", "fonte", "dados", "informação", "percentual de", "de acordo com"
Estatística e Probabilidade	"probabilidade", "chance", "possibilidade", "risco", "média", "mediana", "moda", "padrão", "desvio", "variância", "amostra", "população", "pesquisa", "entrevista", "frequência", "urna", "bola", "sorteio", "retirar", "acaso", "aleatório", "distribuição", "regularidade", "precipitação", "chuva"

Fonte: gerada pelo autor.

B) STOPWORDS

As stopwords correspondem a palavras que são desconsideradas pelo algoritmo durante o processo de classificação textual. Em geral, tratam-se de termos com baixa relevância semântica e alta frequência de ocorrência, que pouco contribuem para a identificação do conteúdo temático do texto. A presença dessas palavras pode introduzir ruído no modelo, uma vez que sua alta frequência tende a influenciar indevidamente os cálculos de relevância dos algoritmos de classificação.

A remoção de stopwords contribui para a simplificação do processamento, pois reduz a quantidade de termos a serem analisados e elimina a necessidade de calcular valores associados a palavras semanticamente irrelevantes. Como consequência, o modelo torna-se mais eficiente e direciona seu foco para termos com maior poder discriminativo.

Dessa forma, a exclusão de palavras como “o”, “do” ou “de”, que não apresentam significado relevante para a tarefa de classificação, evitam interpretações equivocadas por parte do algoritmo. Caso essas palavras sejam mantidas, sua alta frequência pode resultar na atribuição de pesos elevados, reduzindo a eficácia do modelo e impactando negativamente sua precisão.

C) IDF SUAVIZADO

O *Inverse Document Frequency* (IDF), conforme explicado anteriormente, representa uma modificação no modelo de classificação com o objetivo de atribuir um peso de relevância a cada palavra, considerando sua distribuição ao longo do conjunto de documentos. No entanto, a formulação tradicional do IDF pode apresentar limitações, como a supervalorização de termos que aparecem muito raramente, o que pode distorcer o processo de classificação.

Para contornar esse problema, foi aplicada uma suavização do IDF, a qual, além de resolver questões matemáticas — como a possibilidade de divisão por zero —, contribui para a correção desse viés. Essa adaptação da fórmula reduz o impacto excessivo de termos extremamente raros, permitindo que o modelo direcione maior atenção a palavras efetivamente relevantes para a distinção entre as disciplinas.

Dessa forma, a utilização do IDF suavizado torna o processo de ponderação mais equilibrado, favorecendo termos com maior poder discriminativo e evitando que palavras pouco representativas exerçam influência desproporcional nos resultados da classificação. O IDF suavizado é aplicado no algoritmo através da Equação 1. Para o cálculo do IDF suavizada, utilizou-se a formulação suavizada padrão da biblioteca Scikit-Learn(2020).

Equação 1: idf suavizado

$$IDF = \log \left(\frac{1 + N}{1 + DF} \right) + 1$$

Onde o N representa o número total de documentos no seu conjunto de dados, o DF apresenta a quantidade de documentos onde a palavra específica aparece.

D) EXPANSÃO AUTOMÁTICA DE VOCABULÁRIO

Conforme discutido anteriormente, o vocabulário constitui um elemento fundamental para a precisão do modelo de classificação, exercendo influência direta sobre seu desempenho. Nesse contexto, foi implementada uma funcionalidade destinada à expansão dinâmica do vocabulário, a qual permite identificar palavras que não

estavam previamente categorizadas, mas que aparecem de forma recorrente nos textos analisados.

Essas palavras são então associadas a determinadas disciplinas com base em sua frequência e contexto de ocorrência, contribuindo para um vocabulário mais representativo e consistente. Esse processo torna o algoritmo mais coeso e melhora sua capacidade de adaptação, preparando o modelo para lidar com novas entradas de dados de forma mais eficiente.

Além disso, essa abordagem dinamiza uma etapa essencial do código, reduzindo a dependência de um vocabulário estático e permitindo ajustes progressivos ao longo do processo de classificação, o que favorece a melhoria contínua do desempenho do modelo.

E) NORMALIZAÇÃO

A normalização atua como um complemento ao modelo TF-IDF, tendo como objetivo evitar que palavras ou textos excessivamente longos exerçam influência desproporcional no processo de classificação. Esse procedimento consiste em ajustar os pesos atribuídos pelo modelo em função do tamanho do texto, garantindo que documentos maiores não obtenham vantagem indevida apenas por conterem um número mais elevado de termos.

Ao normalizar os vetores de pesos, o modelo passa a considerar a distribuição relativa dos termos, em vez de seus valores absolutos, o que possibilita um ajuste mais refinado dos resultados. Como consequência, a normalização contribui para uma maior estabilidade e precisão do modelo, tornando o processo de classificação mais consistente e comparável entre diferentes questões.

3.2.9 CLASSIFICADOR FINAL

Mesmo após a aplicação de técnicas de otimização, o baixo volume de dados disponível dificulta a obtenção de níveis elevados de precisão sem incorrer em *overfitting* ou introduzir viés no modelo. Diante dessa limitação, optou-se por direcionar os esforços para outros aspectos relevantes da avaliação.

Assim, o foco principal passou a ser a maximização da precisão em todas as disciplinas, buscando uma distribuição mais equilibrada dos resultados, bem como a redução da dispersão entre as métricas de desempenho. Essa abordagem visa garantir maior consistência no comportamento do modelo, priorizando a generalização e a estabilidade dos resultados em detrimento de uma otimização excessiva para um conjunto de dados restrito.

Dessa forma, a Tabela 2 evidencia a diferença de desempenho entre os dois algoritmos, apresentando a precisão por disciplina e a precisão global, considerando o conjunto completo das 45 questões analisadas.

Tabela 2 : comparação entre o algoritmos TF-IDF e o TF-IDF Melhorado.

Disciplinas	TF-IDF	TF-IDF MELHORADO
Aritmética	42,86%	57,14%
Estatística e Probabilidade	83,33%	50,00%
Geometria	100,00%	83,33%
Grandezas e Medidas	28,57%	57,14%
Gráficos e Tabelas	20,00%	40,00%
Proporcionalidade e Variação	50,00%	100,00%
Álgebra e Funções	37,50%	62,50%
TOTAL	51.11%	64.44%

Fonte: gerada pelo autor

A partir dos dados apresentados na Tabela 2, observa-se que o modelo aprimorado não apresentou um aumento expressivo na precisão média, registrando um acréscimo de pouco mais de 13% em relação ao modelo anterior. Entretanto, um aspecto relevante a ser destacado é o fato de que a precisão tornou-se mais equilibrada entre as diferentes disciplinas.

Nota-se que, embora a menor precisão continue ocorrendo na disciplina de Gráficos e Tabelas em ambos os modelos, no modelo aprimorado houve um aumento de aproximadamente 20% nesta categoria. Esse comportamento indica uma melhoria

na distribuição do desempenho, o que contribui para uma maior robustez do modelo.

Esse balanceamento torna o classificador mais adequado para lidar com novos dados, uma vez que demonstra sua capacidade de classificar questões de diferentes disciplinas com um nível mínimo de confiabilidade, reduzindo a dependência de um desempenho elevado concentrado em poucas categorias

Também é possível observar, a partir dos dados apresentados na Tabela 3, que o balanceamento das questões classificadas pelo modelo apresenta maior proximidade com a distribuição observada nas provas reais do ENEM. Dessa forma, o número de questões categorizadas em cada disciplina tornou-se mais coerente com os valores efetivamente encontrados nas avaliações oficiais.

Tabela 3 : dispersão das classificações por disciplina e comparação com o gabarito apresentado na coluna DR (Dispersão Real).

Disciplinas	TF-IDF	TF-IDF MELHORADO	DR
Aritmética	10	9	6
Estatística e Probabilidade	9	8	8
Geometria	7	7	5
Grandezas e Medidas	7	7	6
Gráficos e Tabelas	6	6	7
Proporcionalidade e Variação	4	5	6
Álgebra e Funções	2	3	7

Fonte: gerada pelo autor.

Apesar dessa melhoria, ainda se verifica a existência de discrepâncias entre a distribuição real das questões e aquela obtida pelo modelo. Conforme evidenciado pelos resultados, ambos os modelos tendem a atribuir maior ênfase às disciplinas de Aritmética e Estatística em detrimento de Álgebra, enquanto, nas provas reais, a

distribuição entre as disciplinas apresenta um comportamento significativamente mais equilibrado.

Esses resultados indicam que, embora o modelo tenha avançado em termos de balanceamento, ainda há espaço para aprimoramentos, especialmente no que se refere à representação proporcional das disciplinas, aspecto que será considerado em etapas futuras do desenvolvimento do trabalho.

3.2.10 VALIDAÇÃO

A etapa de validação foi realizada utilizando as questões do ENEM 2024, permitindo a avaliação do modelo com dados do mesmo nível e características semelhantes àqueles empregados na fase de testes. Essa abordagem possibilita uma análise mais realista do desempenho do classificador.

Para isso, foi aplicado às questões de 2024 o mesmo procedimento anteriormente adotado para as questões de 2023. Inicialmente, os dados foram organizados em um arquivo no formato .csv, contendo o corpo das questões, o qual foi posteriormente processado pelo modelo desenvolvido.

Os resultados obtidos por meio da classificação automática foram então comparados com o gabarito, utilizando um conjunto de dados não previamente visto pelo modelo. Dessa forma, essa etapa configura uma avaliação em condições próximas a um cenário real de aplicação, permitindo verificar a capacidade de generalização e a confiabilidade do modelo proposto.

Utilizando o mesmo procedimento anteriormente aplicado às questões de 2023, este foi igualmente estendido às questões do ENEM 2024, possibilitando a construção de um novo conjunto de dados destinado à etapa de análise. Ressalta-se que, durante esse processo, não foram realizadas alterações no vocabulário, tampouco modificações significativas na implementação do código.

Dessa forma, foi possível obter os seguintes resultados, os quais são apresentados e discutidos a seguir na Tabela 4. A coluna TF-IDF Total representa o desempenho do modelo considerando o conjunto de dados completo, formado pela união dos *datasets* de 2023 e 2024. Essa abordagem permite avaliar o comportamento do

classificador em um cenário mais amplo, no qual há maior diversidade de questões e maior variabilidade lexical. as outras colunas são os resultados obtidos em cada ano respectivamente.

Tabela 4: validação do algoritmo com os dados do ano de 2024.

Disciplinas	TF-IDF 2024	TF-IDF 2023 Melhorado	TF-IDF TOTAL
Aritmética	30,00%	57,14%	29,41%
Estatística e Probabilidade	50,00%	50,00%	50,00%
Geometria	100,00%	83,33%	80,00%
Grandezas e Medidas	28,57%	57,14%	71,10%
Gráficos e Tabelas	50,00%	40,00%	55,55%
Proporcionalidade e Variação	16,66%	100,00%	50,00%
Álgebra e Funções	50,00%	62,50%	43,75%
total	42.22%	64.44%	52.22%

Fonte: gerada pelo autor.

Ao analisar os resultados, observa-se que, quando aplicado a um ambiente contendo questões novas, como no caso exclusivo de 2024, o modelo TF-IDF Melhorado apresentou uma redução aproximada de 20% na taxa de acerto total em comparação ao desempenho obtido em 2023. Esse comportamento era esperado, uma vez que o modelo passa a lidar com dados não previamente vistos, o que evidencia de forma mais realista sua capacidade de generalização.

Apesar dessa queda global, nota-se que algumas disciplinas, como Geometria, mantiveram níveis elevados de precisão, indicando que o vocabulário associado a essa área é mais consistente e bem representado no modelo. Em contrapartida, disciplinas como Proporcionalidade e Variação de Grandezas e Medidas apresentaram maior variação nos resultados, sugerindo maior sensibilidade à diversidade textual das questões.

No conjunto TF-IDF Total, observa-se uma melhora no desempenho geral em relação aos dados de 2024 isoladamente, atingindo uma precisão total de 52,22%, o

que indica que o aumento do volume de dados contribui positivamente para a estabilidade do modelo. Ainda assim, a diferença entre os resultados por disciplina evidencia que o classificador não responde de forma homogênea a todas as áreas do conhecimento.

Esses resultados reforçam a importância da validação com dados inéditos e demonstram que, embora o modelo TF-IDF apresente desempenho satisfatório, há espaço para aprimoramentos, especialmente no refinamento do vocabulário e no balanceamento das disciplinas, visando melhorar sua capacidade de generalização em cenários reais de aplicação.

4. RESULTADOS E DISCUSSÕES

4.1 ANÁLISE EXPLORATÓRIA

Após a criação e validação do algoritmo, tornou-se possível aplicá-lo à análise dos microdados do ENEM 2023, com o objetivo de identificar as principais deficiências de aprendizagem dos alunos com deficiência que realizaram a prova laranja.

Inicialmente, foi conduzida uma análise exploratória dos dados abertos disponibilizados, visando obter uma visão geral da estrutura, da distribuição e das principais características do conjunto de dados. Essa etapa é fundamental para compreender o comportamento das variáveis, identificar padrões, inconsistências e limitações, além de subsidiar as análises posteriores de forma mais consistente e orientada.

4.1.1 COMPARATIVO ENTRE AS PROVAS

Analisando os dados foi possível segmentar os dados por cor de prova, permitindo identificar, por exemplo, o número de participantes que realizaram a prova laranja, conforme apresentado no Quadro 3.

Quadro 3: Quantidade de alunos que fizeram a prova de matemática do Enem no ano de 2023.

cor da prova	número da prova	registros
azul	1213.0	671183
amarela	1214.0	665869
rosa	1212.0	665399
cinza	1211.0	664706
rosa(Ampliada)	1215.0	3306

cor da prova	número da prova	registros
cinza (reaplicação)	1294.0	1304
rosa(reaplicação)	1293.0	1295
amarela (reaplicação)	1292.0	1290
Azul (reaplicação)	1291.0	1289
Verde (Vídeo Prova)	1219.0	1199
Laranja (Leitor)	1218.0	663
rosa(SuperAmpliada)	1216.0	641
Laranja braile	1217.0	120

Fonte: gerada pelo autor.

A tabela evidencia que a porcentagem de alunos que realizaram alguma prova com recursos de acessibilidade (como as provas laranja, verde ou rosa super ampliadas) é bastante reduzida em relação ao total de participantes, representando apenas 0,097%. Especificamente em relação à prova laranja, apenas 783 alunos a realizaram, o que corresponde a 0,068% do total — um número significativamente inferior quando comparado ao universo de candidatos.


4.1.2 MÉDIA GERAL POR COR DE PROVA

Ao segmentar os alunos com base na cor das provas, é possível analisar a distribuição de suas respectivas notas. Embora as diferentes cores de prova não apresentem variações significativas em seu conteúdo — alterando-se apenas a ordem das questões —, observam-se pequenas diferenças nas médias gerais entre elas. Essas variações, no entanto, estão dentro da margem de erro de 4,5, conforme indicado pela variância dos dados.

O Gráfico 1, apresenta os dados das quatro principais versões de prova, que juntas representam mais de 98% do total de participantes. No caso da prova laranja, foram

considerados os dados tanto da versão com auxílio de leitor quanto da versão em braile. Em comparação com os dados em verde que representam a média das notas obtidas por todos os alunos que realizaram cada uma dessas versões da prova.

Gráfico 1 – O gráfico apresenta a média das notas por cor de prova.



Fonte: gerada pelo autor.

No interior de cada coluna, está indicado o número total de alunos que realizaram aquela versão da prova, enquanto no topo de cada coluna encontra-se o valor da média correspondente à respectiva amostra.

4.2 ANÁLISE DAS QUESTÕES

Dando prosseguimento à análise que constitui o objetivo final deste projeto, iniciou-se a construção de um dataset composto exclusivamente por alunos que realizaram a prova laranja, totalizando pouco mais de 120 participantes que fizeram a prova de leitor, os outros 663 fizeram outras modalidades da prova laranja. Esse conjunto de dados continha inicialmente apenas o número de matrícula de cada aluno e duas colunas principais: TX_RESPOSTAS_MT, correspondente às

respostas assinaladas pelo aluno, e TX_GABARITO_MT, referente ao cartão respostas, que representa as respostas corretas segundo o ENEM.

Contudo, cada registro dessas colunas era composto por um texto contínuo contendo todas as alternativas marcadas ao longo da prova, o que dificultava a análise direta do desempenho individual por questão. Diante dessa limitação, foi realizado um processo de transformação dos dados, no qual se construiu um novo *Data Frame* contendo exclusivamente as respostas organizadas por questão.

Nesse novo formato, cada coluna passou a representar uma questão, enquanto cada linha corresponde a um aluno. Os valores foram codificados de forma binária, sendo atribuído 1 para respostas corretas e 0 para respostas incorretas, com base na comparação direta com o cartão respostas. A partir dessa estrutura, tornou-se possível obter uma visão mais clara e objetiva do desempenho geral dos alunos, cujos resultados são apresentados no Gráfico 2 localizado no apêndice módulo 8 do trabalho.

A partir da análise do desempenho individual dos alunos, tornou-se possível agrupar as questões por disciplina, permitindo responder às indagações que motivaram a criação deste projeto. Essa organização viabiliza uma avaliação mais precisa das dificuldades enfrentadas pelos estudantes em cada área do conhecimento.

Para isso, foram conduzidas duas análises distintas. A primeira utiliza as classificações geradas pelo algoritmo proposto, enquanto a segunda baseia-se no gabarito previamente construído, utilizado como referência para a validação do modelo. Esse gabarito indica a disciplina correta de cada questão, permitindo estabelecer uma base comparativa confiável.

Dessa forma, é possível analisar o desempenho do algoritmo em um cenário real de aplicação, verificando como ele se comporta ao processar dados reais e identificando a discrepância entre as classificações automáticas e a classificação real das questões. Essa comparação é essencial para avaliar a eficácia do modelo e compreender suas limitações frente à realidade observada.

a) ANÁLISE DOS DADOS USANDO O TF-IDF

A Tabela 5 apresenta os resultados da análise de desempenho dos alunos utilizando a classificação gerada pelo algoritmo TF-IDF. São apresentados indicadores estatísticos como média, mediana, desvio padrão, além dos valores mínimos e máximos de acerto por disciplina.

Tabela 5: Resultados da análise de desempenho dos alunos utilizando a classificação gerada pelo algoritmo TF-IDF.

Classificação tfidf	<i>mean</i>	<i>median</i>	<i>std</i>	<i>min</i>	<i>max</i>
Aritmética	21,83%	21,67%	11,61%	8,33%	40,0%
Estatística e Probabilidade	18,33%	18,33%	5,56%	11,67%	25,0%
Geometria	21,48%	20,83%	8,69%	10,83%	39,17%
Grandezas e Medidas	26,19%	24,17%	7,33%	19,17%	39,17%
Gráficos e Tabelas	32,00%	26,67%	19,81%	17,05%	65,83%
Proporcionalidade e Variação	23,33%	23,75%	9,02%	6,67%	36,67%
Álgebra e Funções	21,81%	20,83%	8,73%	8,33%	34,17%

Fonte: gerada pelo autor.

As médias de acerto por disciplina permanecem em faixas semelhantes, variando aproximadamente entre 18% e 32%, o que indica que o modelo consegue representar de maneira consistente o comportamento real dos alunos.

As medianas também se mantêm próximas às médias, sugerindo uma distribuição equilibrada dos dados. Disciplinas como Gráficos e Tabelas novamente apresentam maior variabilidade, evidenciada por um desvio padrão elevado, o que indica diferenças acentuadas no desempenho dos alunos nessa área específica.

b) ANÁLISE DOS DADOS USANDO O GABARITO

Iniciando a análise a partir do gabarito, a Tabela 6 apresenta um conjunto de indicadores estatísticos relevantes extraídos dos dados, incluindo a média, mediana, desvio padrão, bem como os valores mínimos e máximos de acerto dos alunos por

disciplina. Esses indicadores permitem uma compreensão mais aprofundada do desempenho dos alunos em cada área avaliada.

Tabela 6: Resultados da análise de desempenho dos alunos utilizando a classificação gerada pela análise do gabarito.

Gabarito	<i>mean</i>	<i>median</i>	<i>std</i>	<i>min</i>	<i>max</i>
Aritmética	21,55%	22,5%	10,36%	8,33%	40%
Estatística e Probabilidade	19,72%	17,5%	7,466%	11,67%	30,83%
Geometria	24,17%	22,92%	8,866%	14,17%	39,17%
Grandezas e Medidas	25,24%	20,83%	9,01%	15%	39,17%
Gráficos e Tabelas	28,5%	19,17%	20,93%	17,5%	65,83%
Proporcionalidade e Variação	23,75%	24,17%	10,47%	6,67%	36,67%
Álgebra e Funções	22,4%	23,75%	7,063%	8,33%	31,67%

Fonte: gerada pelo autor.

A média geral de acertos por disciplina evidencia que, de modo geral, os alunos apresentam dificuldades em todas as matérias analisadas, com percentuais médios de acerto variando aproximadamente entre 19% e 28%. Esse resultado está diretamente relacionado à nota média obtida pelos estudantes, que foi em torno de 400 pontos, indicando um desempenho global abaixo do esperado.

Ao observar as medidas de tendência central, nota-se que as medianas acompanham valores próximos às médias, o que sugere uma distribuição relativamente homogênea dos resultados em grande parte das disciplinas.

Dessa forma, a análise do gabarito fornece uma visão consistente do cenário real enfrentado pelos estudantes, servindo como referência fundamental para as análises subsequentes realizadas com o uso do algoritmo, além de contribuir para a validação dos resultados obtidos ao longo do desenvolvimento do projeto.

4.3 COMPARAÇÃO DOS RESULTADOS

De forma geral, observa-se que os resultados obtidos por meio do algoritmo não

diferem significativamente daqueles encontrados na análise realizada com base no gabarito.

Ao comparar os valores mínimos e máximos, observa-se que o algoritmo preserva a capacidade de identificar tanto alunos com baixo desempenho quanto aqueles com resultados expressivos, comportamento semelhante ao observado na análise baseada no gabarito. Esse aspecto reforça a robustez do modelo ao lidar com dados reais.

A Tabela 7 apresenta a comparação entre as médias de acerto por disciplina obtidas a partir da análise do gabarito e daquela realizada por meio da classificação utilizando o algoritmo TF-IDF, bem como o módulo da diferença entre esses valores. Essa comparação permite avaliar o grau de proximidade entre os resultados produzidos pelo modelo e a situação real observada.

Tabela 7: Comparativo entre as médias de acerto por disciplina e a baseada no gabarito por meio da classificação utilizando o algoritmo TF-IDF.

Disciplinas	gabarito	classificação tfidf	diferença
Aritmética	21,55%	21,83%	0,28%
Estatística e Probabilidade	19,72%	18,33%	1,39%
Geometria	24,17%	21,48%	2,69%
Grandezas e Medidas	25,24%	26,19%	0,95%
Gráficos e Tabelas	28,5%	32,00%	3,50%
Proporcionalidade e Variação	23,75%	23,33%	0,42%
Álgebra e Funções	22,4%	21,81%	0,59%

Fonte: gerada pelo autor.

De maneira geral, observa-se que as médias obtidas pelo algoritmo não diferem significativamente dos valores reais, indicando que o modelo consegue representar de forma consistente o desempenho dos alunos por disciplina. As diferenças observadas permanecem baixas na maioria dos casos, com variações inferiores a 1 ponto percentual em disciplinas como Aritmética, Grandezas e Medidas, Proporcionalidade e Variação e Álgebra e Funções.

A principal discrepância é observada na disciplina de Gráficos e Tabelas, que apresentou uma diferença de 3,50 pontos percentuais entre a classificação do algoritmo e os dados baseados no gabarito. Esse comportamento sugere que o modelo tende a superestimar o desempenho nesta área, possivelmente em função de características específicas do vocabulário ou da estrutura textual das questões associadas a essa disciplina.

Ainda assim, considerando o conjunto das disciplinas, os resultados reforçam que o algoritmo TF-IDF apresenta um bom alinhamento com os dados reais, sendo capaz de fornecer estimativas próximas ao desempenho efetivo dos alunos. As variações identificadas, em especial em Gráficos e Tabelas, serão analisadas com maior profundidade em etapas posteriores, a fim de compreender suas causas e possíveis estratégias de correção.

5 CONCLUSÃO E TRABALHOS FUTUROS

Este estudo investigou a viabilidade do uso de algoritmos de classificação léxica para categorizar questões de Matemática do ENEM por disciplina e aplicar essa categorização na análise do desempenho de estudantes em uma situação real de prova. Foram analisadas e comparadas diferentes abordagens, desde métodos baseados em regras até técnicas de vetorização textual mais robustas. Entre os modelos avaliados, o método baseado em TF-IDF apresentou o desempenho mais consistente, destacando-se pelo equilíbrio entre as disciplinas e pela manutenção de níveis mínimos satisfatórios de acerto em diferentes cenários. Tal estabilidade mostrou-se particularmente relevante diante do tamanho reduzido do conjunto de dados, limitação que restringe o uso de modelos mais complexos baseados em aprendizado profundo.

Os resultados também evidenciaram a relevância de componentes estruturais do modelo, como a construção do vocabulário, o tratamento de stopwords, a suavização do IDF e a normalização vetorial, os quais contribuíram para a redução de ruídos e maior robustez das classificações. Observou-se, entretanto, que a expansão indiscriminada do vocabulário pode comprometer o poder discriminativo e aumentar o risco de overfitting, reforçando a necessidade de ajustes criteriosos. Na validação com dados inéditos, verificou-se uma redução aproximada de 20% na precisão geral, comportamento esperado em cenários de generalização, mas ainda com coerência estatística e distribuição de classificações próxima à observada nas provas reais.

Na análise do desempenho dos estudantes, os resultados obtidos por meio da classificação automática mostraram forte proximidade com aqueles derivados das análises utilizando o gabarito oficial, com diferenças médias reduzidas entre as disciplinas e variações mais perceptíveis apenas na área de Gráficos e Tabelas. Esse achado indica que, mesmo com limitações, o modelo consegue representar adequadamente o comportamento dos dados reais, demonstrando potencial para apoiar análises educacionais exploratórias.

As técnicas clássicas de Processamento de Linguagem Natural, como o TF-IDF, constituem uma alternativa eficiente, interpretável e adequada ao contexto investigado, especialmente quando há restrição de dados.

Como trabalhos futuros, recomenda-se a ampliação e diversificação da base de dados, o refinamento contínuo do vocabulário e a investigação de abordagens híbridas que combinem métodos léxicos e semânticos, com o objetivo de elevar a precisão sem comprometer a capacidade de generalização. Além disso, sugere-se explorar técnicas de aprendizado supervisionado com *embeddings* pré-treinados e análises mais aprofundadas do impacto pedagógico das classificações no acompanhamento do desempenho estudantil.

6 REFERÊNCIAS BIBLIOGRÁFICAS

BRASIL. Programa Internacional de Avaliação de Estudantes (PISA). [Documento eletrônico]. Brasília: INEP, 2025. Disponível em:
<https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/pisa#:~:text=O%20Pisa%20oferece%20informa%C3%A7%C3%B5es%20sobre,principais%20fatores%20que%20moldam%20sua>. Acesso em: 28 maio 2025.

BRASIL. Microdados do Enem. [Documento eletrônico]. Brasília: INEP, 2025. Disponível em:
<https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados/enem>. Acesso em: 28 maio 2025.

ENEM, MATRIZ DE REFERÊNCIA DO ENEM. Brasília: Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira – INEP, 2025. Disponível em:
https://download.inep.gov.br/download/enem/matriz_referencia.pdf. Acesso em: 14 agosto de 2025.

BRASIL. Exame Nacional do Ensino Médio (Enem). [Documento eletrônico]. Brasília: INEP, 2025. Disponível em:
<https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/enem#:~:text=Os%20participantes%20fazem%20provas%20de,todo%20somam%20180%20quest%C3%B5es%20objetivas>. Acesso em: 28 maio 2025.

INEP (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira). Provas e Gabaritos — ENEM. Brasília: INEP, s.d. Disponível em:
<https://www.gov.br/inep/pt-br/areas-de-atuacao/avaliacao-e-exames-educacionais/enem/provas-e-gabaritos>. Acesso em: 14 ago. 2025.

VAN ROSSUM, Guido. The Making of Python. Artima Developer. 2003. Disponível em: <https://www.artima.com/articles/the-making-of-python>. Acesso em: 4 junho 2025.

GOOGLE. Google Colaboratory.2025 Disponível em: <https://colab.google>.
Acesso em: 4 junho 2025.

BELINI, Gustavo Torres; ATAIDE, Danilo da Silva; LOCHTER, Johannes Von.
Modelo de Machine Learning para Predição de Problemas Respiratórios. Facens
Centro Universitário, Sorocaba, 2024.Disponível em:
https://www.ciaca-conf.org/wp-content/uploads/2024/12/CIACA2024_PT_F_021_Belini.pdf. Acesso em: 4 junho 2025.

Romero, C., & Ventura, S. (2010). Educational data mining: a review of the state of the art. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 40(6), 601-618. Disponível em:
<https://doi.org/10.1109/TSMCC.2010.2053532> Acesso em: 15 junho 2025.

Sebesta, R. W. (2009). Concepts of Programming Languages (10ª ed.). Pearson.
Disponível em: <https://www.ime.usp.br/~alvaroma/ucsp/proglang/book.pdf> Acesso em: 15 junho 2025.

PYTHON SOFTWARE FOUNDATION. (2025)
The Python Standard Library. Python Documentation, versão 3.13.
Disponível em: <https://docs.python.org/pt-br/3.13/library/index.html>. Acesso em: 17 julho 2025.

BARROS, Abílio Nogueira; SILVA, Danielle Karla Alves da; ADEODATO, Paulo J. L.
Mineração de Dados nos Hábitos de Estudo: Uma Análise para o Desempenho no ENEM 2022. Anais do XXXV Simpósio Brasileiro de Informática na Educação (SBIE), 2024. Disponível em:
<https://sol.sbc.org.br/index.php/sbie/article/view/31460/31263>. Acesso em: 17 julho 2025.

BARCELLOS, Alessandro Aparecido; ISOTANI, Seiji; DAMASCENO, Carlos Diego Nascimento. Mineração de Dados Abertos – ENEM 2018. Anais dos Trabalhos de Conclusão de Curso da Pós-Graduação em Computação Aplicada à Educação – ICMC/USP, São Carlos, 2020. Disponível em:

https://especializacao.icmc.usp.br/documentos/tcc/alessandro_barcellos.pdf. Acesso em: 17 julho 2025.

NAKAZONE Eduardo Yoshinori; BORTOLOTTI, Luis Marcelo. Análise de Dados Históricos do ENEM entre 2015 à 2019 utilizando Python + Pandas. In: Congresso Tecnológico da Fatec Mococa, v. 4, n. 1, 2021. Disponível em: <https://congresso.fatecmococa.edu.br/index.php/congresso/article/view/169/61>. Acesso em: 17 julho 2025.

Lima, P. da S. N., Ambrósio, A. P. L., Ferreira, D. J., & Brancher, J. D.. (2019). Análise de dados do Enade e Enem: uma revisão sistemática da literatura. Avaliação: Revista Da Avaliação Da Educação Superior (campinas), 24(1), 89–107. Disponível em: <https://doi.org/10.1590/S1414-40772019000100006>. Acesso em: 17 julho 2025.

REPLIT (2025). Plataforma de programação online Replit. Disponível em: <https://replit.com>. Acesso em: 01 ago. 2025.

R CORE TEAM. R: A Language and Environment for Statistical Computing. Vienna: R Foundation for Statistical Computing, 2024. Disponível em: <https://www.r-project.org>. Acesso em: 01 ago. 2025.

SHMUELI, G.; BRUCE, P. C.; GEDI, N. R.; PATEL, N. R. Data Mining for Business Analytics: Concepts, Techniques, and Applications with R. 1. ed. New Jersey: Wiley, 2016. Disponível em: <https://books.google.com.br/books?hl=pt-BR&lr=&id=la87CwAAQBAJ&oi=fnd&pg=PR17&dq=Data+Mining+for+Business+Analytics:+Concepts,+Techniques,+and+Application&ots=so83C-mwCe&sig=Zv lauDiL11hszNQX34wYmmVD2W4#v=onepage&q=Data%20Mining%20for%20Business%20Analytics%3A%20Concepts%2C%20Techniques%2C%20and%20Application&f=false> Acesso em: 01 ago. 2025.

HAN, J.; KAMBER, M.; PEI, J. Data Mining: Concepts and Techniques. 3. ed. San Francisco: Morgan Kaufmann, 2012. Acesso em: 01 ago. 2025. Disponível

em:<https://homes.di.unimi.it/ceselli/IM/2012-13/slides/02-KnowYourData.pdf> Acesso em: 08 ago. 2025.

PEREIRA, C. A. B. Estatística Aplicada à Pesquisa Científica. 3. ed. São Paulo: Edusp, 2020. Acesso em: 01 ago. 2025. Disponível em: https://biblioteca.unisced.edu.mz/bitstream/123456789/1532/1/Metodologia-da-Pesquisa-Cientifica_final.pdf Acesso em: 08 ago. 2025.

ROBERTSON, Stephen E.; ZARAGOZA, Hugo. The Probabilistic Relevance Framework: BM25 and Beyond. 2009. Disponível em: https://www.researchgate.net/publication/220613776_The_Probabilistic_Relevance_Framework_BM25_and_Beyond. Acesso em: 01 ago. 2025.

TAHA, Kamal; YOO, Paul D.; YEUN, Chan; HOMOUZ, Dirar; TAHA, Aya. A comprehensive survey of text classification techniques and their research applications: Observational and experimental insights. Computer Science Review, v. 54, p. 100664, 2024. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1574013724000480>. Acesso em: 01 fev. 2026.

MANNING, Christopher D.; RAGHAVAN, Prabhakar; SCHÜTZE, Hinrich. Introduction to Information Retrieval. Stanford University, 2008. Disponível em: <https://nlp.stanford.edu/IR-book/>. Acesso em: 01 fev. 2026.

SCIKIT-LEARN. `sklearn.feature_extraction.text.TfidfVectorizer`. Machine Learning in Python, 2020=. . Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html. Acesso em: 15 fev. 2026.

ZBS, ENEM QUESTÕES. São Paulo: ZBS Digital, 2026. Disponível em: <https://www.zbs.com.br/enemquestoes>. Acesso em: 27 fevereiro de 2026.

APÊNDICE

Gráfico 2: porcentagem de acertos por questão

